



功能簡介

國考題庫

醫葯集錦

中藥百科

中醫藥材Chatbot

系統研究目標

本系統旨在建構一套以大型語言模型為核心之中醫藥材知識系統，評估 Supervised Fine Tuning 技術對於專業中醫語境下之實務可行性。整合了數位化知識庫、動態模擬測驗與自主研發之 BianCang-Qwen2-7B 模型，提供一站式的學習與研究環境。

中藥百科 & 醫葯

收錄 300 種常用中藥材之多媒體資料庫，包含性味、歸經、主治及考據。整合「醫葯」經典文獻，實現非結構化文獻之結構化重組。

國考模擬 & 驗證

整合民國 94 至 114 年間中醫師國考題庫。透過模擬測驗 (5-50 題) 檢驗學習成效，並作為 LLM 模型性能評測之基準。

當前學習摘要

300

中藥總數



上次得分

專題編號：PRJ2025-001

中醫藥材知識系統：
語言模型於中醫藥材知識微調訓練與驗證研究

專題學生：張詠翔、官翰、簡祥竹

指導教授：曾明性 博士



中山醫學大學 醫學資訊學系



研究背景與挑戰

大型語言模型在中醫領域面臨專業知識內化不足的困境

Zhang、Tian 與 Wang(2025)於其綜述研究中指出，近年來大型語言模型（LLMs）在醫學領域展現潛力，但應用於中醫等高度專業領域時，因知識語義抽象與術語繁多，面臨嚴峻挑戰，比較了GPT系列在Basic Chinese Medicine考試中，於 2021 年 7 月至 2024 年 2 月不同考試階段的準確率如右圖上半[2]。



專業知識內化不足

模型理解多停留於表層語義匹配，缺乏對中醫核心理論的深度認知。



作答穩定性有限

推理結果未必符合中醫理論邏輯，常在藥性判斷與證候分析上出現錯誤。




缺乏適切評測機制

現有指標難以有效驗證模型在專業語境下的可靠性與一致性。

Jan學者等人提出如右圖下半[1]：

- 低效學習模型（LLM）目前存在的限制。
- ChatGPT架構的簡化設計，包括訓練、基於人類回饋的強化學習迭代、可用模型的選擇以及為提高安全性而實施的防護措施。



透過參數高效微調策略提升中醫專業知識的模型內化能力

本研究採用監督式微調（SFT）結合 LoRA 策略，在保留預訓練模型能力的同時，以較為低算力成本注入中醫專業知識，解決通用模型在專業領域的不足。

✓ 建立評估框架

建構兼具效能、穩定性與可解釋性的多維度評測標準。

✓ 國考題庫評測


以中醫國家考試選擇題為場域，針對藥材領域進行監督微調。

✓ 開發備考系統

設計完整的中醫藥材領域備考系統，驗證實務應用可行性。

✓ 模型內化知識

實現不依賴外部檢索（RAG）的知識內化，
提升推理速度與穩定性。



Zhang學者等人提出中醫邏輯模式的工作流程如上圖[3]：

- 中醫邏輯模型在臨床決策支援中的應用涉及一個精簡的流程，該流程始於古代文獻、臨床記錄和結構化資料集等各種來源收集數據。

本研究主要使用山東省科學院齊魯工業大學計算學部自然語言處理與認知計算團隊、山東省中醫藥大學附屬醫院臨床研究中心合作完成之BianCang-Qwen2.5-7B開源模型進行微調實驗[4]。

LoRA策略的發展與效果、評估指標的應用與意義

LoRA策略的發展與效果

Hu 等人於 2021 年提出 Low-Rank Adaptation(LoRA)作為一種參數高效微調方法，透過在 Transformer 權重中引入低秩分解矩陣，僅訓練少量新增參數即可完成下游任務適配，同時保留原始預訓練權重不變[5]。針對本研究的核心問題為「模型是否能內化中醫藥材知識，並在無外部輔助下穩定作答」，LoRA 已成為參數高效微調研究中的核心方法之一[6]。

評估指標的應用與意義

信心差距(Confidence Margin)定義為最高與次高對數機率選項之差，用以衡量模型於候選答案間的判斷確信程度。相關研究指出，基於 margin 的信心度量能較單一最大機率更有效反映模型的真實信心狀態，特別適用於不確定性與校準分析；資訊熵(Entropy)作為衡量機率分布不確定性的指標，可反映模型於作答時的猶豫程度，較高熵值通常對應較高的預測風險[7]。為進一步檢驗模型信心與實際正確率之關係。

本研究分析 Accuracy 隨信心區間變化的趨勢，以進行模型校準(Calibration)評估，可用以判斷模型是否具備「高信心對應高正確率」的合理行為。

McNemar's test 進行配對樣本之統計檢定[8]。該方法專注於分析兩模型在相同樣本上的不一致預測，能有效排除樣本難度差異所造成的干擾，提供微調效能是否具統計顯著性的嚴謹判斷[9]。

基於 LoRA 微調策略與對數機率推理的系統化評估方法



所有實驗皆固定隨機種子(seed)，並重複執行十次，最終結果以平均值±標準差呈現，以確保實驗結果之穩定性與可信度。

研究基礎

資料來源

民國 94-114 年中醫師國家考試**1,751 題**
純文字選擇題，專注於中藥材領域知識

{ "query": "下列何者適用於風熱臂痛及腳氣浮腫的治療？

\n(A)羌活 (B)桑枝 (C)獨活 (D)薑黃"response": " (B) "}

基礎模型

BianCang-Qwen2.5-7B

具備中醫藥材與中文語境先備知識
適合作為專業微調基底

核心技術

LoRA 微調策略

依據 Baichuan 訓練配置

監督微調 (SFT)

使用 Hugging Face Trainer 框架進行

推理方法設計

基於 **Token 對數機率 (Log-prob)** 進
行推理評分

限制輸出單一選項 (A/B/C/D)

給定 prompt 為題目 + 「答案：」

評估驗證

效能指標

作答正確率 (Accuracy)

信心差距 (**Confidence Margin**)

資訊熵 (Entropy)

統計檢定

McNemar's test

檢驗微調前後差異顯著性

分析配對樣本不一致性

LoRA 微調策略與訓練設定

低秩適應技術降低計算成本並保留預訓練模型能力

核心概念：LoRA (Low-Rank Adaptation) 透過在 Transformer 權重中引入低秩分解矩陣，僅訓練少量新增參數即可完成下游任務適配，同時保留原始預訓練權重不變，大幅降低顯存需求。

LoRA 參數配置

```
# === LoRA 參數設定 ===
LORA_R = 8 # rank, 通常 4/8/16
LORA_ALPHA = 16 # scaling factor, 通常 16 或 32
LORA_DROPOUT = 0.05 # dropout 機率

# Baichuan/Lingdan-13B-Base 用的 target modules
# 參考 Baichuan 官方與 LLaMA-Factory 的設定
LORA_TARGET_MODULES = ["W_pack", "o_proj", "gate_proj", "up_proj", "down_proj"]

# 若 model 是 k-bit (例如 load_in_4bit=True), 需要先 prepare
try:
    model = prepare_model_for_kbit_training(model)
    print("Prepared model for k-bit training")
except Exception as e:
    print("prepare_model_for_kbit_training skipped or failed:", e)

# 建立 LoRA 設定
lora_config = LoraConfig(
    r=LORA_R,
    lora_alpha=LORA_ALPHA,
    lora_dropout=LORA_DROPOUT,
    target_modules=LORA_TARGET_MODULES,
    bias="none",
    task_type="CAUSAL_LM",
)
```

低秩矩陣維度 Rank (r)

8

縮放係數 Alpha

32

Dropout

0.1

Target Modules

Attention & FFN

訓練環境設定

Quantization

4-bit + PEFT

Batch Size

3 (per GPU)

Gradient Accumulation

6

Learning Rate

2e-5

Supervision Strategy

Prompt Masking

```
training_args = TrainingArguments(
    output_dir=CHECKPOINT_DIR,
    per_device_train_batch_size=BATCH_SIZE,
    gradient_accumulation_steps=GRAD_ACCUM,
    num_train_epochs=4,
    learning_rate=2e-5,
    fp16=True,
    logging_steps=1,
    save_strategy="steps",
    save_steps=10,
    remove_unused_columns=False,
    report_to="wandb",
    run_name=f"{TCM_model}_sft_run_1",
)
```



01

輸入設定

將題目與固定 Prompt 組合作為模型輸入。

```
"你是一位嚴謹的中醫國考選擇題作答系統。\\n"  
"請選出最正確的答案。\\n\\n"  
f"{question}\\n\\n"  
"答案："
```



02

前向傳播 (Forward Pass)

模型進行推理，取得最後一個時間步的 Logits 分佈。



03

信心計算

將 Logits 轉換為對數機率，提取 A、B、C、D 對應的分數。



04

最終決策

比較各選項分數，選擇對數機率最高者作為預測結果。

$$P(t|context) = \frac{e^{z_t}}{\sum_{i=1}^V e^{z_i}}$$

*其中 z_t ：模型對 token t 的 logit， V 則表示詞彙表大小



$$\log P(t|context) = z_t - \log \left(\sum_{i=1}^V e^{z_i} \right)$$



$$score(X) = \max_{t \in tokens(X)} \log P(t)$$



$$\hat{y} = \arg \max_{X \in \{A, B, C, D\}} score(X)$$



實驗結果：微調效能顯著提升

作答正確率提升 $14.68\% \pm 0.00\%$ ，展現模型內化知識策略成效

環境使用套件紀錄：

```
pip install -U "transformers" "tokenizers" "accelerate" "huggingface_hub" "safetensors" "sentencepiece"  
pip install peft==0.10.0  
pip install bitsandbytes  
pip install numpy==1.26.4  
pip install wandb==0.16.6
```

訓練趨勢圖與訓練統計結果紀錄：



Summary metrics: {} 11 keys

final_train_loss: 1.078093513861968

total_flos: 748,694,060,673,269,760

train_loss: 1.078093513861968

train_runtime: 12,123.9593

train_samples_per_second: 2.84

train_steps_per_second: 0.158

train/epoch: 3

train/global_step: 1,914

train/grad_norm: 2.8443124294281006

train/learning_rate: 0.00000010449320794148

train/loss: 0.6723

壹、緒論

貳、文獻回顧

參、研究方法

肆、研究成果


伍、討論

陸、結論

實驗結果：微調效能顯著提升

作答正確率提升 $14.68\% \pm 0.00\%$ ，展現模型內化知識策略成效

模型作答正確率比較 (%)



McNemar's Test 統計檢定 Table

Total paired samples: 1751	LoRA ✓	LoRA ✗
Base ✓	934	83
Base ✗	340	394

基礎錯 → 微調對 (改善)

340

基礎對 → 微調錯 (退步)

83

統計顯著性 (p-value)

1.44×10^{-34}

Statistic = 154.93 (高度顯著差異)


總樣本數

1,751 題

中醫藥材相關純文字選擇題

信心分析：模型展現合理校準行為

微調後模型在高信心情境下具備更佳的判斷一致性



信心差距分析

Confidence Margin

正確樣本顯著集中於
高差距區間

微調後的模型在正確作答時，最高選項與次高選項的機率差距拉大。與錯誤樣本的分布重疊程度顯著降低，顯示模型能有效區分「確信」與「猜測」的狀態。



資訊熵分佈

Entropy Distribution

正確樣本高度集中於
低熵值區域

低熵值代表模型對預測結果的不確定性較低。數據顯示，模型在高信心情境下具備極佳的判斷一致性，減少了模稜兩可的隨機推論。



校準曲線

Accuracy vs Confidence

正確率隨信心提升而
穩定上升

兩者呈現高度正相關，證明模型具備良好的校準性(Calibration)。模型的高信心確實對應高正確率，而非盲目自信或過度保守。



系統開發：中醫藥材知識系統

整合中醫藥材資料、國考題庫與 AI 模型的一站式智慧輔助平台

來源：<https://yibian.hopto.org/?lc=tw>



中藥百科

標準化數位藥材庫，收錄 300 種常用中藥材。

高解析度圖片對照

性味歸經與功能主治



醫藥集錦

深入中醫理論核心，整合深度醫學文獻與方劑知識。

科屬來源與炮製方法

現代藥理研究



國考題庫

整合民國 94-114 年國考題庫，提供實戰模擬。

自動計時與即時評分

錯題回顧機制



中醫藥材 Chatbot

內建微調後的 BianCang-Qwen2.5-7B 模型。

自然語言問答互動

不依賴外部搜尋引擎



來源：<https://reurl.cc/VmQ6ab>

壹、緒論

貳、文獻回顧

參、研究方法

肆、研究成果

伍、討論








陸、結論

掃描我進系統




系統開發：中醫藥材知識系統

整合中醫藥材資料、國考題庫與 AI 模型的一站式智慧輔助平台



跨模型比較實驗

BianCang-Qwen2.5-7B 在各階段國考題目中皆優於 Lingdan-13B



模型名稱 (Model)	第一階段： 基礎醫學 (3,583 題)	第二階段： 臨床醫學 (7,893 題)	
Lingdan-13B-Base	32.65%	31.58%	(一)
Lingdan-13B-Base_LoRA	58.36%	47.15%	(二)
BianCang-Qwen2.5-7B	62.35%	60.97%	(三)
BianCang-Qwen2.5-7B_LoRA	78.79%	77.54%	(四)

跨架構有效性

基於 LoRA 的微調策略在不同基礎模型架構下皆能穩定提升效能，證明了該方法在專業領域知識注入上的通用性。

領域資料 > 參數規模

經領域資料微調的 7B 模型表現顯著優於未微調的 13B 模型，顯示在中醫專業任務中，資料品質與適配性比單純增加模型參數更為關鍵。

錯誤題目進行轉移學習延伸實驗

模型	「第一階段：基礎醫學」3583 題	「第二階段：臨床醫學」7893 題
QLU-NLP/BianCang-Qwen2.5-7B_ LoRA	78.79% $\pm$ 0.00%	77.54% $\pm$ 0.00%
QLU-NLP/BianCang-Qwen2.5-7B_ LoRA_DPO	79.12% $\pm$ 0.00%	77.71% $\pm$ 0.00%
QLU-NLP/BianCang-Qwen2.5-7B_ LoRA_KTO	78.90% $\pm$ 0.00%	77.54% $\pm$ 0.00%
QLU-NLP/BianCang-Qwen2.5-7B_ LoRA_ORPO	78.76% $\pm$ 0.00%	77.54% $\pm$ 0.00%
QLU-NLP/BianCang-Qwen2.5-7B_ LoRA_GRPO	78.37% $\pm$ 0.00%	76.97% $\pm$ 0.00%

於既有 LoRA 微調模型基礎上進一步導入偏好學習方法，其整體效能提升幅度有限，顯示在中醫專業選擇題任務中，領域資料本身對模型效能之影響程度，明顯高於單純增加模型參數量或偏好式微調策略所帶來的增益。

模型內化式微調策略為中醫 AI 應用奠定基礎

學術貢獻

系統化評估框架

建立結合正確率、信心差距與資訊熵的多維度指標，解決傳統單一指標無法反映模型可靠性的問題。

LoRA 微調效益驗證

證實監督微調 (SFT) 能在有限算力下，有效將專業領域知識內化至通用語言模型中。

對數機率的客觀評分機制

透過引入 Token 對數機率 (Log-prob) 進行推理評分，量化信心程度，避免非標準化輸出，確保評估客觀性。

實務應用

完整系統整合

開發整合中藥百科、醫碁集錦、國考題庫與 AI Chatbot 的一站式輔助系統，落實研究成果。

國考備考輔助

提供歷年題庫模擬與即時解析，協助考生在真實情境中驗證學習成效與知識盲點。

專業問答能力

展示模型在不依賴外部搜尋 (RAG) 下，仍具備邏輯一致且準確的中醫專業問答能力。

參考文獻

- [1] Clusmann, Jan, et al. "The future landscape of large language models in medicine." *Communications medicine* 3.1 (2023): 141.
- [2] Wu, Yun-Chi, et al. "GPT-3.5, GPT-4, and GPT-4o Performance in the Traditional Chinese Medicine Licensing Examination in Taiwan: The Need for Improved Reliability in AI Solutions." (2025).
- [3] Zhang, Ruyi, Dingcheng Tian, and Yu Wang. "Large language models in traditional chinese medicine: A short survey and outlook." *AI Medicine* 2.1 (2025): 3.
- [4] Wei, Sibo, et al. "Biancang: a traditional chinese medicine large language model." *IEEE Journal of Biomedical and Health Informatics* (2025).
- [5] Hu, Edward J., et al. "Lora: Low-rank adaptation of large language models." *ICLR* 1.2 (2022): 3.
- [6] Hu, Jerry Yao-Chieh, et al. "Computational Limits of Low-Rank Adaptation (Lora) Fine-Tuning for Transformer Models." *The Thirteenth International Conference on Learning Representations*. 2025.
- [7] Yona, Gal, Amir Feder, and Itay Laish. "Useful confidence measures: Beyond the max score." *arXiv preprint arXiv:2210.14070* (2022).
- [8] Sumler, Daniel James, et al. "An Entropic Metric for Measuring Calibration of Machine Learning Models." *arXiv preprint arXiv:2502.14545* (2025).
- [9] Martinović, Marko, Kristian Dokic, and Dalibor Pudić. "Comparative Analysis of Machine Learning Models for Predicting Innovation Outcomes: An Applied AI Approach." *Applied Sciences* 15.7 (2025): 3636.

結論與回顧

實驗軌跡回顧與致謝



銘謝

本研究涉及大量參數之模型權重訓練，其算力資源主要來自：

- 中山醫學大學醫學資訊學系提供之AI Server，GPU Config為NVIDIA Geforce 3090 *5。
- Glows.ai platform，GPU Config為A100*1及NVIDIA Geforce 4090*1，並採用平台提供之Liger Kernel有效提升訓練效率。

GPU	Name	Fan	Temp	Perf	Persistence-M	Bus-Id	Disp.A	Volatile	Uncorr.	ECC
					Pwr:Usage/Cap		Memory-Usage	GPU-Util	Compute M.	MIG M.
0	NVIDIA GeForce RTX 3090	35%	58C	P2	148W / 350W	Off	00000000:1D:00.0 Off 10101MiB / 24576MiB	19%	Default	N/A
1	NVIDIA GeForce RTX 3090	37%	71C	P2	330W / 350W	Off	00000000:1F:00.0 Off 17541MiB / 24576MiB	95%	Default	N/A
2	NVIDIA GeForce RTX 3090	39%	78C	P2	177W / 350W	Off	00000000:20:00.0 Off 13609MiB / 24576MiB	57%	Default	N/A
3	NVIDIA GeForce RTX 3090	37%	63C	P2	186W / 350W	Off	00000000:21:00.0 Off 13609MiB / 24576MiB	63%	Default	N/A
4	NVIDIA GeForce RTX 3090	36%	63C	P2	188W / 350W	Off	00000000:23:00.0 Off 13609MiB / 24576MiB	0%	Default	N/A

GPU	Name	Fan	Temp	Perf	Persistence-M	Bus-Id	Disp.A	Volatile	Uncorr.	ECC
					Pwr:Usage/Cap		Memory-Usage	GPU-Util	Compute M.	MIG M.
0	NVIDIA A100-SXM4-80GB	N/A	48C	P0	208W / 400W	On	00000000:27:00.0 Off 54973MiB / 81920MiB	79%	Default	Disabled
0	NVIDIA GeForce RTX 4090	37%	62C	P2	379W / 450W	On	00000000:17:00.0 Off 13433MiB / 24564MiB	100%	Default	N/A
0	NVIDIA GeForce RTX 4090	0%	56C	P2	346W / 450W	On	00000000:17:00.0 Off 16217MiB / 24564MiB	93%	Default	N/A

左為中山醫學大學醫學資訊學系提供之AI Server NVIDIA Geforce 3090 *5於Lingdan-13B-Base訓練實驗之算力需求紀錄

右上為Glows.ai platform，GPU Config為A100*1於Lingdan-13B-Base_LoRA推理測試之算力需求紀錄

右中為Glows.ai platform，GPU Config為NVIDIA Geforce 4090*1於BianCang-Qwen2.5-7B訓練實驗之算力需求紀錄

右下為Glows.ai platform，GPU Config為A100*1於BianCang-Qwen2.5-7B_LoRA推理測試之算力需求紀錄

專題學生：張詠翔、官翰、簡祥竹

指導教授：曾明性 博士

專題編號：PRJ2025-001



中山醫學大學 醫學資訊學系

